




# Машинное обучение

## Лекция 2. Линейные модели. Градиентный спуск

(10.02.2024)

Даниил Литвинов



---

# Общие сведения

# План



1. Линейная модель регрессии ✓
2. Как линейные модели обучаются? ✓
3. Линейная модель классификации ✓


# Что это такое?



$x$  — баллы за экзамен по английскому 1

$y$  — баллы за экзамен по английскому 2

$x$	$y$
1	5
3	11
9	35
10	33



Что это такое?

$$\hat{y} = w_0 + w_1 x$$


свободный член  
(intercept)

случайная ошибка  
(error)

$$y = w_0 + w_1 x + \epsilon$$


целевая переменная  
(aka target)

независимая переменная  
(slope, predictor)



А какая модель нам нужна?

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \rightarrow \min$$




# Интерпретация коэффициентов




# Зачем нужны линейные модели?

1. Предсказание интересующей нас величины
2. Оценка влияния различных факторов на нашу целевую переменную
3. Линейные модели очень легко использовать и интерпретировать
4. Линейные модели могут восстанавливать даже **нелинейные зависимости**






А если у нас много независимых переменных?



$$y = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n + \epsilon$$

площадь	число комнат	школа близко	цена квартиры
50	2	нет 0	5000
1000	7	да 1	11000
30	1	нет	3500
100	4	нет	33333

# Множественная линейная регрессия дает нам плоскость



# Производные



$$y \sim x$$

$$\frac{dy}{dx} = \frac{y(x_0 + \Delta x) - y(x_0)}{\Delta x}$$

$y = f(x)$	$\frac{dy}{dx} = f'(x)$
$k$ , any constant	0
$x$	1
$x^2$	$2x$
$x^3$	$3x^2$
$x^n$ , any constant $n$	$nx^{n-1}$
$e^x$	$e^x$
$e^{kx}$	$ke^{kx}$
$\ln x = \log_e x$	$\frac{1}{x}$
$\sin x$	$\cos x$
$\sin kx$	$k \cos kx$
$\cos x$	$-\sin x$
$\cos kx$	$-k \sin kx$

## Производные

$$\varphi(x, y, z) = 2x^2 + 3y^2 - \sin z$$

$$\frac{\partial \varphi}{\partial x} = 4x$$

$$\frac{\partial \varphi}{\partial y} = 6y$$

$$\frac{\partial \varphi}{\partial z} = -\cos z$$

$$\begin{pmatrix} 4x \\ 6y \\ -\cos z \end{pmatrix}$$

градиент

$\nabla \varphi$  - градиент

# Производные

- Град. указ. в напр. наиб. роста ф-ции.
- Антиград. ~ наоборот.



$$\frac{dy}{dx}(x_1) > 0$$

$$\frac{dy}{dx}(x_2) < 0$$

~~$$x_3 + \frac{dy}{dx}(x_3)$$~~

$$x_3 - \frac{dy}{dx}(x_3)$$

# Производные



# Как оценивать коэффициенты модели?

$$\hat{y} = w_0 + w_1 x_1 + \dots + w_3 x_3$$

$$\begin{matrix} X, & y, & w \\ n \times 3 & n \times 1 & 4 \times 1 \end{matrix}$$

$$\begin{bmatrix} 1 & x_1 & x_2 & x_3 \\ \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

$$\begin{matrix} & n \times 3 & , & 4 \times 1 \\ y \approx & X & \cdot & w \\ n \times 1 & & & \end{matrix}$$

$$\rightarrow \begin{bmatrix} 1 & x_1 & x_2 & x_3 \\ \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} \cdot \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ w_3 \end{pmatrix} =$$

$$\begin{matrix} & n \times 4 & & 4 \times 1 \\ y = & X & \cdot & w \\ n \times 1 & & & \end{matrix} \rightarrow \begin{pmatrix} 1 \cdot w_0 + x_1 \cdot w_1 + \dots + x_3 \cdot w_3 \\ \vdots \\ \vdots \end{pmatrix} = \begin{pmatrix} \hat{y} \\ \vdots \\ \vdots \end{pmatrix} = y$$

$$\hat{y} = X \cdot w$$

Как оценивать коэффициенты модели?

$$MSE = \frac{1}{N} (y - Xw)^T \cdot (y - Xw)$$

$n \times 1$       $n \times 4$     $4 \times 1$


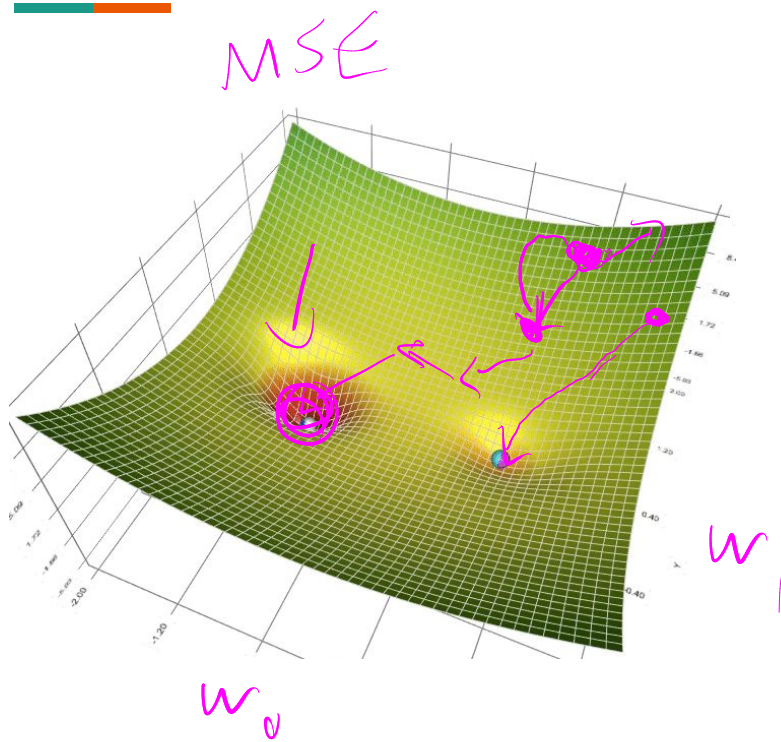
функционал  
потерь  
Loss

~~$n \times 1 \cdot 1 \times n \rightarrow n \times n$~~

$$\nabla_{\underset{4 \times 1}{w}} MSE = -\frac{1}{N} \cdot 2 \cdot \underset{n \times 4}{X^T} \cdot (\underset{n \times 1}{y} - Xw) = \boxed{\frac{2}{N} X^T (Xw - y)}$$



# Градиентный спуск



## Формулы



✓  $y = w_0 + w_1 x + \epsilon$

✓  $y = Xw$

✓  $Loss = (y - Xw)^T (y - Xw)$

✓  $\frac{dLoss}{dw} = \nabla Loss = 2X^T(Xw - y)$



$w = (X^T X)^{-1} X^T y$


## Градиентный спуск



$$Loss = (y - Xw)^T (y - Xw) \quad \frac{dLoss}{dw} = \nabla Loss = 2X^T (Xw - y)$$

```
w = np.random.randn(m + 1)
Пока grad(Loss) != 0:
    w -=  $\eta$  * grad(Loss)
```


$\eta$  — learning rate  
[0.001, 0.01]



---

**Отдых -> логистическая регрессия**

## Связь событий и признаков



В зависимости от предикторов события могут происходить чаще или реже – логика, совпадающая с логикой связи количественной переменной отклика с набором предикторов.


Например, по мере роста температуры воздуха летом чаще будут встречаться люди в шортах: событие “встретился человек в шортах” положительно связано с температурой воздуха.

Событие “проведение исследования” явно связана с предиктором “объем полученного финансирования”, однако эта связь может быть совсем непростой.

# А что если хотим классификацию?



Допустим бинарная классификация



## Отношение шансов



Шансы (odds) часто представляют в виде отношения шансов (odds ratio)

Если отношение шансов  $> 1$ , то вероятность наступления события выше, чем вероятность того, что оно не произойдет.

Если отношение шансов  $< 1$ , то наоборот.

Если можно оценить вероятность положительного события, то отношение шансов выглядит так:

$$odds = \frac{\pi}{1-\pi}$$

Отношение шансов варьируется от 0 до  $+\infty$ .

Попробуем сами





# Логиты



Отношение шансов можно преобразовать в логиты(logit):



$$\ln(odds) = \ln\left(\frac{\pi}{1 - \pi}\right)$$

- Значения логитов – это трансформированные оценки вероятности события.
- Логиты варьируют от  $-\infty$  до  $+\infty$ .
- Логиты симметричны относительно 0, т.е.  $\ln(1)$ .
- Для построения моделей в качестве зависимой переменной удобнее брать логиты.

# Считаем вероятность



## Дискретные значения vs вероятности




# Как такое учить? BCE Loss



# Качество классификации



# Качество классификации. ROC кривая



[рисуем свою ROC кривую](#)

# Построение ROC кривой

